



Universidade Federal de São João del Rei
Departamento de Ciência da Computação
Curso de Ciência da Computação

Algoritmo Genético 3 - Problema da Mochila binária

Adélson de Oliveira Carmo Júnior
212050019

1 Como executar o programa:

O programa possibilita a passagem de valores para o número de gerações e o tamanho da população como parâmetros, o que facilita a realização de novos testes para uma compreensão mais aprofundada do seu funcionamento. Para utilizar o programa, basta fornecer a sua versão do Python, o nome do arquivo, o tamanho da população, o número de gerações desejado, qual penalização aplicar (0 para branda e 1 para severa) e se deseja mostrar (0 para não e 1 para sim) o gráfico ou não seguindo a ordem exemplificada abaixo:

```
1 python3.11 ag1.py 100 1000 1 1
```

Além disso, para o funcionamento adequado do programa, é essencial que os arquivos de entrada estejam localizados na mesma pasta do programa, devidamente nomeados e preenchidos conforme demonstrado abaixo

- **p_c.txt:** Contém a capacidade da mochila binária;
- **p_w.txt:** Fornece o peso de cada item;
- **p_p.txt:** Indica o valor associado a cada item.

2 Resultados esperados

Após a execução do programa, serão gerados três arquivos de texto. Dois destes arquivos irão apresentar o melhor indivíduo de todas as gerações executadas pelo algoritmo genético nos dois métodos de escolha de pais, torneio e roleta, conforme ilustrado nas Figuras 1 e 2. O terceiro arquivo contém a resposta obtida após as gerações, onde os elementos selecionados para compor a melhor solução são representados por 0s e 1s, conforme exemplificado na Figura 3. Além disso, se a opção de impressão de gráfico for solicitada durante a execução, um gráfico será gerado para mostrar a evolução dos melhores resultados ao longo das gerações nos testes, em ambos os métodos.

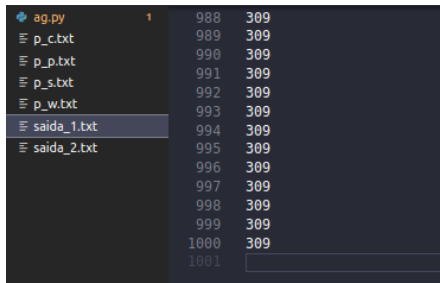


Figura 1: Melhores resultados usando Torneio

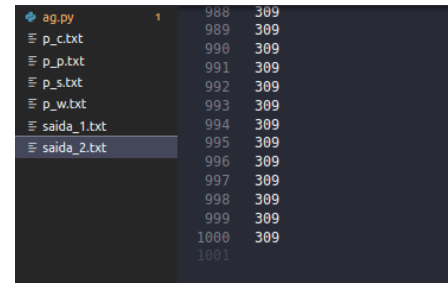


Figura 2: Melhores resultados usando Roleta

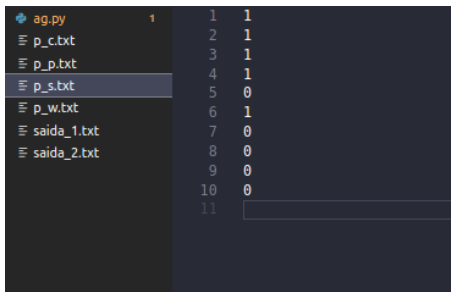


Figura 3: Melhor resultado entre os dois testes

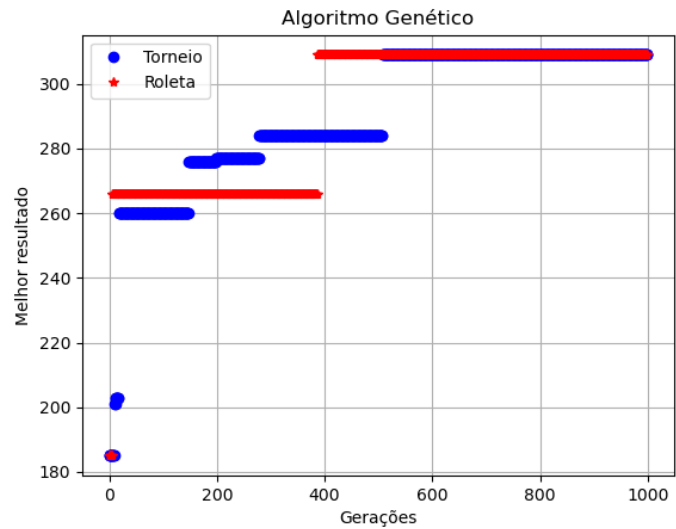


Figura 4: Gráfico do melhor indivíduo de cada geração

3 Testes e análise de resultados

Com o objetivo de compreender o desempenho do algoritmo genético em diferentes cenários, foram conduzidos diversos testes, nos quais variáveis cruciais, como a presença de elitismo e o tamanho da população, foram modificadas. Nesta seção, serão apresentados os resultados obtidos nestes experimentos e as conclusões que são possíveis de extrair sobre o algoritmo com base neles.

Os testes foram realizados usando um outro código, também em Python, além do código principal. Esse código adicional permitia a realização de vários testes e a geração de gráficos a partir dos resultados.

Nesta seção, foram mantidos alguns parâmetros constantes para explorar o impacto de um em particular. O padrão utilizado foi o seguinte:

- Método da Roleta;
- Tamanho da população: 100 indivíduos;
- Taxa de mutação: 1% em condições normais e 10% caso o melhor elemento permaneça inalterado após 5 gerações;
- Taxa de cruzamento: 100%;
- Com elitismo;
- Número de gerações: 100;

- Penalização severa;
- Entradas com instância de número "01"

3.1 Método de escolha de pais

Para uma análise inicial, optou-se por examinar o comportamento geral entre os dois métodos de seleção de pais, o Torneio e a Roleta. Assim, foram conduzidos 100 testes utilizando ambos os métodos, mantendo certos parâmetros constantes citados anteriormente.

Os resultados desses testes podem ser observados nas Figuras 5 e 6. Vale ressaltar que eles foram ordenados do menor ao melhor em ambos os métodos, proporcionando uma melhor visualização. Além disso, foram utilizadas sempre a mesma população inicial em ambos os métodos.

É possível notar que, salvo raras exceções, o método da Roleta encontrou o melhor resultado em um menor número de gerações, conforme mostrado pela Figura 5. Além disso, em termos do melhor resultado em si, novamente o método da Roleta demonstra superioridade em relação ao seu concorrente. A Roleta encontrou o número desejado mais vezes; no entanto, quando não o encontrou, obteve um valor próximo. Por outro lado, o método do Torneio, além de encontrar o valor desejado menos vezes, quando não o encontrou, apresentou dois valores, sendo um menor que o outro, como evidenciado pela Figura 6

Dessa forma, tanto em eficiência quanto em encontrar o melhor resultado, o método da Roleta se mostra a melhor escolha.




Figura 5: Gerações para encontra o melhor indivíduo

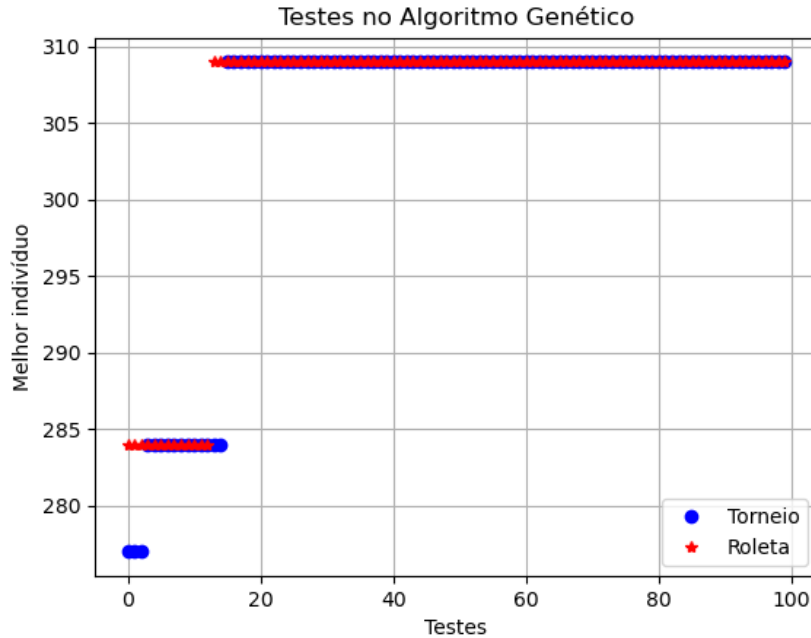


Figura 6: Melhores valores em cada teste

3.2 Tamanho da população

De forma semelhante à seção anterior, com o objetivo de estudar as alterações que um parâmetro causa no sistema, manteremos os demais constantes. Assim, os mesmos parâmetros citados anteriormente serão utilizados, exceto pelo tamanho da população, que será variado. Além disso, o método da roleta será o único utilizado para conduzir os testes, de agora em diante.

Novamente, foram conduzidos 100 testes, porém, desta vez, o tamanho da população foi a variável escolhida. Opta-se por três tamanhos diferentes de população: 20, 50 e 100 indivíduos. Os resultados desses testes podem ser observados nas figuras 7 e 8.

Ao analisar a figura 7, percebe-se que o tamanho da população influencia a eficiência do sistema. Conforme o tamanho da população aumenta, torna-se mais rápido encontrar o melhor elemento. A população de 20 indivíduos foi mais lenta do que a de 50, que, por sua vez, mostrou-se menos eficiente do que a de 100 elementos. No entanto, é importante observar que, embora a população de 20 indivíduos tenha sido a mais lenta, ela encontrou o número desejado para o melhor valor o mesmo número de vezes que a população de 100. Por outro lado, a população de 50 indivíduos foi a menos eficaz, encontrando menos vezes o número desejado para o melhor valor.

Portanto, os resultados sugerem que a eficácia do sistema varia de acordo com o tamanho da população, sendo que uma população maior tende a ser preferível.




Figura 7: Gerações para encontra o melhor indivíduo




Figura 8: Melhores valores em cada teste

3.3 Taxa de mutação

Semelhante ao processo realizado na seção anterior, alguns parâmetros serão mantidos constantes enquanto varia-se aquele que deve ser estudado. Desta vez, o foco será na taxa de mutação, mantendo constante a população de 100 indivíduos.

Para a variação, foram adotadas três porcentagens diferentes: 1%, 5% e 10%, e os resultados dos 100

testes realizados podem ser observados nas figuras 9 e 10. Analisando a primeira dessas figuras, nota-se que quando a taxa é de 5%, há uma maior eficiência em relação às demais. No entanto, as outras duas porcentagens estão bem próximas uma da outra, com a de 10% sendo ligeiramente melhor.

Por outro lado, quando se trata de encontrar o valor desejado para o melhor resultado, a situação se inverte. O melhor nesse quesito é o de 1%, enquanto o de 5% é o pior. O de 10% demonstra mais consistência, apresentando apenas outros 2 números como melhores resultados alternativos, ao contrário do de 1%, que apresenta 3. Além disso, o de 10% apresenta uma superioridade em relação ao de 5% em termos de encontrar o melhor valor.

Em suma, tanto a opção de 1% quanto a de 10% são viáveis, cada uma com seus pontos fortes e fracos. Em relação à eficiência e consistência dos resultados, o de 10% é superior, mas quando se trata de encontrar o melhor valor, o de 1% é a melhor escolha




Figura 9: Gerações para encontra o melhor indivíduo




Figura 10: Melhores valores em cada teste

3.4 Taxa de cruzamento

Mantendo a ideia de conservar alguns parâmetros, pode-se observar o comportamento de um em específico, por meio da sua variação. Neste tópico será estudada a taxa de cruzamento, seguindo o padrão anterior.

As porcentagens utilizadas para os 100 testes foram as seguintes: 60%, 80% e 100%. Ao analisar a Figura 11, percebe-se uma nítida diminuição das gerações necessárias para encontrar o melhor indivíduo à medida que essa taxa diminui. Portanto, a taxa de 60% demonstrou ser a mais eficiente, seguida por 80% e, por fim, 100%. Essa tendência é confirmada pela Figura 12, onde novamente a taxa de 60% resultou em mais indivíduos com o valor desejado para o melhor elemento, seguida por 80% e 100%, sendo esta última a menos eficaz.

Dessa forma, conclui-se que o uso de uma taxa de cruzamento menor resultou em uma melhoria tanto na eficiência quanto na capacidade de encontrar o melhor indivíduo, conforme sugerido pelos gráficos.




Figura 11: Gerações para encontra o melhor indivíduo

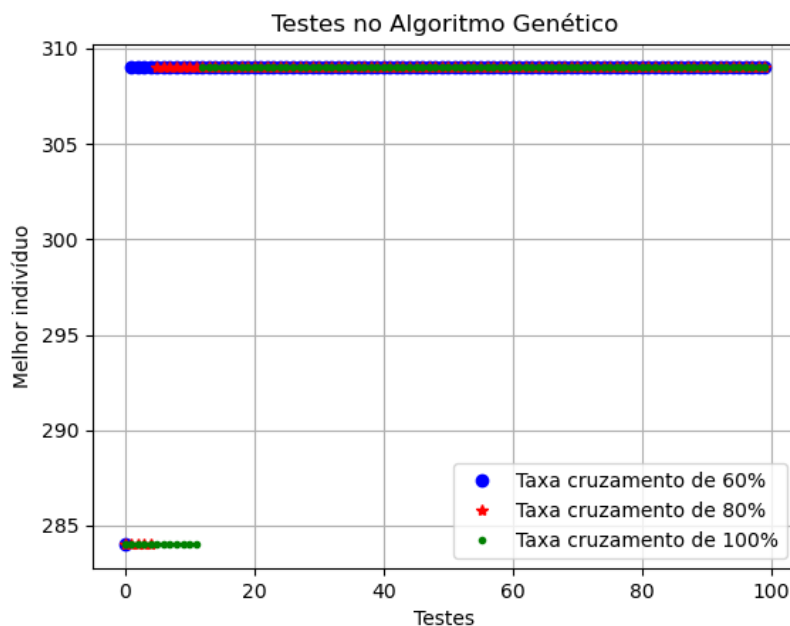


Figura 12: Melhores valores em cada teste

3.5 Presença de elitismo

A abordagem de teste nesta seção se concentra em avaliar o impacto do elitismo no desempenho do algoritmo genético. Ao analisar as figuras 13 e 14, fica evidente que o elitismo desempenha um papel crucial na estabilidade e na eficiência do algoritmo.

Na figura 13, observa-se uma dispersão significativa dos pontos quando o elitismo não é empregado. Muitos

pontos estão abaixo do eixo x, indicando flutuações nos resultados ao longo das gerações. Essa instabilidade é causada pela ausência de uma manutenção do melhor valor, resultando em mudanças frequentes no melhor indivíduo encontrado.

Por outro lado, na figura 14, onde o elitismo é aplicado, observa-se uma estabilidade notável ao longo das gerações. Os pontos se mantêm consistentemente próximos aos valores desejados, sem flutuações significativas. Isso evidencia que a preservação do melhor indivíduo ao longo das gerações proporcionada pelo elitismo contribui para a consistência e a eficácia do algoritmo genético.

Portanto, fica claro que o elitismo é um fator crucial para o bom funcionamento do algoritmo genético, garantindo uma busca mais eficiente e estável pelo melhor indivíduo. Sua presença proporciona uma base sólida para o algoritmo, ajudando a evitar flutuações indesejadas nos resultados e aumentando a probabilidade de convergência para soluções ótimas.




Figura 13: Comparação com e sem elitismo

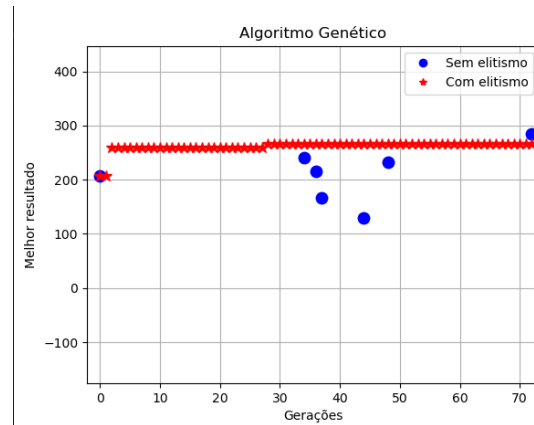


Figura 14: Aproximando dos resultados com elitismo

3.6 Número de gerações

Nesta seção, o número de gerações foi variado enquanto os demais parâmetros foram mantidos constantes. Ao analisar os resultados apresentados nas figuras 15 e 16, fica claro que o número de gerações tem um impacto significativo no tempo necessário para encontrar o melhor indivíduo e na qualidade da solução encontrada.

A figura 15 demonstra que, conforme o número de gerações aumenta, o tempo necessário para encontrar o melhor indivíduo também aumenta. Isso é esperado, pois mais gerações permitem que o algoritmo explore mais completamente o espaço de busca em busca da solução ótima. Como resultado, o teste com 1000 gerações levou mais tempo para encontrar o melhor elemento, seguido por 500 e 250 gerações.

No entanto, a figura 16 revela uma observação importante sobre a qualidade da solução encontrada em relação ao número de gerações. Embora um número menor de gerações possa levar menos tempo para encontrar um indivíduo ótimo, não garante necessariamente a qualidade desse indivíduo. Descobriu-se que, com mais gerações, o valor encontrado para o melhor indivíduo era igual ao esperado. Logo, ao diminuir o número de gerações, houve uma tendência de diminuição do valor encontrado.

Portanto, enquanto um número menor de gerações pode proporcionar menos tempo para o algoritmo explorar o espaço de busca, isso não garante que a solução encontrada seja necessariamente a melhor possível. É importante considerar um equilíbrio entre o número de gerações e a qualidade da solução desejada, ajustando o número de gerações conforme necessário para atender aos requisitos específicos do problema.




Figura 15: Gerações para encontra o melhor indivíduo




Figura 16: Melhores valores em cada teste

3.7 Penalizações

Sendo essa o último parâmetro ainda não testado, nessa seção será explorado qual o impacto dos tipos de penalizações na avaliação do algoritmo genético, mantendo os demais constantes.

Ambos as penalizações foram aplicadas em 100 testes, sempre com a mesma entrada para garantir que os dados possam ser avaliados mais fielmente. A figura 17, corresponde ao número de gerações que foram necessárias para encontrar o indivíduo e embora as duas penalizações não apresentem grandes diferenças, a severa apresentou uma maior eficiência ao necessitar de menos gerações para encontrar o melhor valor, na maioria dos testes.

A Figura 18 confirma a suspeita da superioridade da abordagem mais severa, uma vez que em mais casos ela encontrou o valor ótimo desejado do que em relação à sua concorrente.

Dessa forma, pode-se definir que para esse algoritmo genético, uma penalização mais severa oferece um resultado melhor que uma branda.




Figura 17: Gerações para encontra o melhor indivíduo

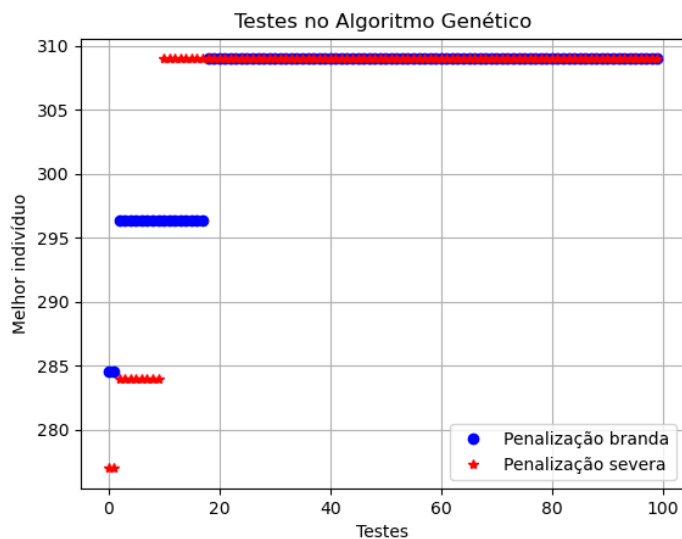


Figura 18: Melhores valores em cada teste